

Métodos Semiparamétricos (GMM) y Optimización en Organización Industrial Empírica

Abriendo la caja negra de la estimación BLP

Juan Diego Barnes

2026

Métodos Econométricos y Organización Industrial Aplicada — Florencia Gabrielli

El objetivo final es que puedan entender que es lo que hace el código de BLP por su cuenta. Para eso reconstruimos la cadena lógica completa:

1. **GMM**: de momentos poblacionales a estimadores muestrales.
2. **GMM como teoría unificadora**: identificación, matriz de ponderación óptima, test J .
3. **Casos particulares**: OLS, IV y 2SLS *via* GMM. Eficiencia bajo heterocedasticidad.
4. **Aplicación**: Card (1995), retornos a la educación.
5. **Implementación**: BLP (1995), Nevo (2000, 2001) y Conlon-Gortmaker (2020) — demanda con coeficientes aleatorios —*GMM no lineal con un punto fijo anidado*—.

1. **La perspectiva de IO sobre la productividad:** A que llamamos productividad?
2. **Un primer en estimación de productividad:** Olley & Pakes (1996) y la función de control.
3. **El “*Production-Approach*”** para recuperar markups (De Loecker, 2011).
4. **Trade-off** entre BLP (demanda) y el Production-Approach; Extensión a *markdowns*.
5. **Extensiones:** Levinsohn–Petrin (2003) y Akerberg–Caves–Frazer (2015).



Momentos poblacionales y el principio de analogía

Momento poblacional

Un *momento* es la esperanza de una función conocida de los datos. Para una v.a. y :

$$\mu = \mathbb{E}(y), \quad \sigma^2 = \mathbb{E}[(y - \mu)^2], \quad \mathbb{E}[(y - \mu)^3]/\sigma^3 \text{ (asimetría)}.$$

Principio de analogía

Si un parámetro poblacional se define como funcional de la distribución F , estimémoslo con el *mismo* funcional aplicado a la distribución empírica $\hat{F}_n$. La esperanza $\mathbb{E}[\cdot]$ se reemplaza por el promedio muestral $n^{-1} \sum_i(\cdot)$.

Caso canónico

Si $\mathbb{E}(y) = \mu$, entonces el estimador de momentos es $\hat{\mu} = \bar{y} = n^{-1} \sum_{i=1}^n y_i$. Bajo muestreo aleatorio, $\bar{y}$ es insesgado, consistente y — con varianza finita — el MELI de μ .

Condiciones de momento: el lenguaje común

Definición general

Sea w_i el vector de datos del individuo i y $\theta \in \Theta \subseteq \mathbb{R}^p$. Una *función de momentos* es una función conocida $g(w_i, \theta) : \mathbb{R}^d \times \Theta \rightarrow \mathbb{R}^q$ tal que, en el verdadero θ_0 ,

$$\boxed{\mathbb{E}[g(w_i, \theta_0)] = 0} \quad (q \text{ condiciones de momento}).$$

Momento poblacional

$$\mathbb{E}[g(w_i; \theta_0)] = 0.$$

Condición sobre la distribución verdadera. Identifica θ_0 pero no es observable.

Análogo muestral

$$\bar{g}_n(\theta) = \frac{1}{n} \sum_{i=1}^n g(w_i; \theta).$$

Promedio observable. La estrategia: hacer que $\bar{g}_n(\hat{\theta}) \approx 0$.

Toda la econometría que sigue es una elección distinta de $g(\cdot)$.

El supuesto identificador

Modelo lineal $y_i = x_i' \beta + u_i$, con $x_i \in \mathbb{R}^k$. La condición de ortogonalidad

$$\mathbb{E}(x_i u_i) = \mathbb{E}[x_i (y_i - x_i' \beta_0)] = 0$$

da $q = k$ momentos para $p = k$ parámetros: **exactamente identificado**.

Función de momentos

$$g(w_i, \beta) = x_i (y_i - x_i' \beta).$$

Análogo muestral = 0

$$\frac{1}{n} \sum_i x_i (y_i - x_i' \hat{\beta}) = 0$$

$$\Rightarrow \hat{\beta} = (X'X)^{-1} X'y.$$

OLS no es “minimizar la suma de cuadrados”: es resolver k condiciones de momento.

Endogeneidad

Si $\mathbb{E}(x_i u_i) \neq 0$, OLS es inconsistente. Supongamos instrumentos $z_i \in \mathbb{R}^q$ con

$$\mathbb{E}(z_i u_i) = \mathbb{E}[z_i(y_i - x_i' \beta_0)] = 0, \quad g(w_i, \beta) = z_i(y_i - x_i' \beta).$$

Justo identificado ($q = k$)

$\bar{g}_n(\hat{\beta}) = 0$ tiene solución única:

$$\hat{\beta}_{IV} = (Z'X)^{-1}Z'y.$$

Sobreidentificado ($q > k$)

$\bar{g}_n(\beta) = 0$ *no* tiene solución en general: q ecuaciones, $k < q$ incógnitas.

¿Qué hacemos con los momentos sobrantes?

Con sobreidentificación GMM responde cómo combinarlos.



Definición (Hansen, 1982)

Dada una matriz de ponderación W_n ($q \times q$, simétrica, definida positiva, con $W_n \xrightarrow{p} W$),

$$\hat{\theta}_{GMM} = \arg \min_{\theta \in \Theta} Q_n(\theta), \quad Q_n(\theta) = \bar{g}_n(\theta)' W_n \bar{g}_n(\theta).$$

Justo identificado ($q = p$)

$\hat{\theta}$ resuelve $\bar{g}_n(\hat{\theta}) = 0$ y $Q_n = 0$. La elección de W_n es irrelevante.

Sobreidentificado ($q > p$)

$\bar{g}_n(\hat{\theta}) \neq 0$ en general. W_n **sí importa**: define qué combinaciones lineales de momentos se acercan más a cero.

$Q_n(\theta)$ es una norma cuadrática de la “distancia a cero” de los momentos.

Identificación global

θ_0 está *globalmente identificado* por las condiciones de momento si

$$\mathbb{E}[g(w_i, \theta)] = 0 \iff \theta = \theta_0.$$

Equivalente: $Q_0(\theta) = \mathbb{E}[g]'W\mathbb{E}[g]$ tiene un **único** minimizador en θ_0 . Necesario $q \geq p$ (condición de orden).

Identificación local: condición de rango

Sea el jacobiano esperado

$$G = \mathbb{E} \left[\frac{\partial g(w_i, \theta_0)}{\partial \theta'} \right] \in \mathbb{R}^{q \times p}.$$

La identificación local requiere $\text{rank}(G) = p$ (rango columna completo). Es la generalización de la condición de rango de IV; su falla es la **identificación débil**.

Resultado de eficiencia (Hansen, 1982)

$V(W)$ se minimiza — en el orden de Loewner, fijando S y el conjunto de momentos — eligiendo $W \propto S^{-1}$. La varianza eficiente es

$$V^* = (G' S^{-1} G)^{-1}.$$

Para cualquier otra W : $V(W) - V^* \succeq 0$ (semidefinida positiva).

Intuición

S^{-1} pondera cada momento por la inversa de su varianza y *descuenta sus covarianzas*: a momentos ruidosos se les baja el peso; a momentos informativos se les sube. Es GLS aplicado al espacio de condiciones de momento.

V^ es óptima dado este conjunto de momentos.*

El problema de huevo y gallina

$W = S^{-1}$ es óptima, pero S depende de θ_0 (desconocido) y de la estructura de dependencia de los datos.

Cross-section / heterocedasticidad

$$\hat{S} = \frac{1}{n} \sum_i g(w_i, \tilde{\theta}) g(w_i, \tilde{\theta})'.$$

Análogo de White: robusto a heterocedasticidad de forma desconocida.

Series de tiempo / dependencia

$$\hat{S} = \hat{\Gamma}_0 + \sum_{j=1}^L k\left(\frac{j}{L}\right) (\hat{\Gamma}_j + \hat{\Gamma}_j').$$

Estimador HAC (Newey–West, 1987): kernel $k(\cdot)$, ventana L .

$\hat{S}$ requiere un $\tilde{\theta}$ consistente previo $\Rightarrow$ procedimiento en dos etapas.

Test J de Hansen (1982)

Con la ponderación eficiente $\hat{W} = \hat{S}^{-1}$, el valor mínimo de la función objetivo escalado por n es informativo:

$$J = n \cdot \bar{g}_n(\hat{\theta})' \hat{S}^{-1} \bar{g}_n(\hat{\theta}) \xrightarrow{d} \chi^2_{q-p} \quad \text{bajo } H_0 : \mathbb{E}[g(w, \theta_0)] = 0,$$

donde q = número de momentos/instrumentos y p = número de parámetros estimados (en el modelo IV, $p = k$).

Qué testea

Las $q - p$ restricciones *sobreidentificadoras*. Si $q = p$ (justo identificado) hay 0 g.l. y el test **degenera** ($J = 0$). Rechazo $\Rightarrow$ mala especificación o instrumentos inválidos.

Advertencias

Generaliza el test de Sargan (1958), que es el caso particular bajo homocedasticidad ($\hat{S} = \hat{\sigma}^2 Z'Z/n$). No identifica *cuál* momento falla; baja potencia y sobre-rechazo con muchos instrumentos débiles.

Identificación débil: cuándo la teoría asintótica falla

El problema

La teoría estándar supone $\text{rank}(G) = p$ “con holgura”. Si G está cerca de ser deficiente (instrumentos débilmente correlacionados con los regresores endógenos), la aproximación es **mala**, aun con n grande.

Síntomas

- GMM en dos etapas sesgado hacia OLS.
- Errores estándar y test J poco confiables.
- F de primera etapa baja (regla de Staiger–Stock: $F < 10$).

Relevante en BLP: los instrumentos pueden ser débiles para los coeficientes aleatorios.



Un ejemplo con dos momentos compitiendo (Wooldridge)

Lo que sabemos *a priori*

Población con $\mu > 0$, donde la teoría impone **dos** restricciones: $\mathbb{E}(y) = \mu$ y $\text{Var}(y) = 3\mu$. Un parámetro, dos momentos $\Rightarrow$ **sobreidentificado**.

Estimador 1: la media

$$\hat{\mu}_1 = \bar{y}.$$

Usa solo $\mathbb{E}(y) = \mu$. $\text{Avar} = 3\mu$.

Estimador 2: la varianza

$$\hat{\mu}_2 = s^2/3.$$

Usa solo $\text{Var}(y) = 3\mu$. $\text{Avar} \approx 18\mu + 2\mu^2$ (mucho mayor).

Por qué combinar puede ganar

Como y es *asimétrica* (Gamma), $\bar{y}$ y s^2 están correlacionados: $\text{Cov} \propto \mathbb{E}[(y - \mu)^3] = 18\mu \neq 0$. Esa covarianza — los términos fuera de la diagonal de S — es precisamente lo que la ponderación óptima $W = S^{-1}$ explota. GMM no elige uno: los *combina*.

Monte Carlo: infactible vs. factible

$R = 4000$ réplicas, $n = 100$, $\mu_0 = 2$, $y \sim \text{Gamma}$ con $\mathbb{E}(y) = \mu$, $\text{Var}(y) = 3\mu$ (momentos consistentes en objetivo y en $\hat{S}$).

Estimador	$\mathbb{E}[\hat{\mu}]$	$\text{SD}(\hat{\mu})$	Efic. rel.
$\bar{y}$ (solo momento 1)	2.00	0.24	1.00
$s^2/3$ (solo momento 2)	2.00	0.65	0.14
GMM óptimo infactible ($W = S^{-1}$ verdadera)	2.01	0.22	1.26
GMM factible two-step ($\hat{W} = \hat{S}^{-1}$)	1.97	0.25	0.95

Combinar SÍ ayuda

Con la W óptima verdadera, GMM **domina** a $\bar{y}$ (ef. 1,26; asintóticamente $V^* = (G'S^{-1}G)^{-1} \Rightarrow$ ef. $\rightarrow 1,30$).

Estimar S cuesta

El two-step *factible* estima $\hat{S}$ con ruido: sesgo de muestra finita (Altonji–Segal 1996). A $n = 100$ queda *por debajo* de $\bar{y}$; la ganancia se materializa al crecer n (iterado/CUE mitigan).

Eficiencia asintótica $\neq$ desempeño en muestra finita.

Wooldridge: “using GMM does not hurt anything” — pero tampoco ayuda en cross-section bien comportada.

*La ventaja de GMM aparece con muchos momentos y dependencia compleja —
El escenario de BLP.*

2SLS es GMM con una ponderación particular

Si elegimos $W_n = (Z'Z/n)^{-1} \dots$

$$\hat{\theta}_{GMM} = (X'P_ZX)^{-1}X'P_Zy, \quad P_Z = Z(Z'Z)^{-1}Z' \quad (\text{la fórmula de 2SLS}).$$

2SLS, IV, OLS, efectos fijos: todos son GMM con una elección de g y de W .

Hasta acá GMM parece una curiosidad técnica.

En IO empírica, GMM es el método de estimación de BLP.

La cadena pedagógica

- **Berry, Levinsohn & Pakes (1995)** — “BLP”: logit con coeficientes aleatorios para automóviles. Resolvió endogeneidad de precios y sustitución realista en un modelo de demanda diferenciada.
- **Nevo (2000 *JEMS*; 2001 *Econometrica*)** — la *Practitioner's Guide* que volvió BLP estimable, más la aplicación a cereales listos para comer.
- **Conlon & Gortmaker (*The RAND Journal of Economics*)** — *Best Practices for Differentiated Products Demand Estimation*, recopilan una guía de prácticas para la estimación, además de ser quienes desarrollaron una herramienta para implementarlo (PyBLP).

El problema de estimación de demanda

Utilidad indirecta (BLP)

$$u_{ijt} = X_{jt} \beta_i + \alpha_i p_{jt} + \xi_{jt} + \varepsilon_{ijt}, \quad \begin{pmatrix} \beta_i \\ \alpha_i \end{pmatrix} = \begin{pmatrix} \beta \\ \alpha \end{pmatrix} + \Pi D_i + \Sigma v_i.$$

D_i : demográficas (CPS/CEX); $v_i \sim N(0, I)$: heterogeneidad inobservable; ε_{ijt} : valor extremo tipo I.

Observable

- Shares de mercado s_{jt}
- Precios p_{jt} , características X_{jt}
- Distribución de D_i

No observable / a estimar

- ξ_{jt} : calidad no medida
- $\theta_1 = (\beta, \alpha)$ lineales
- $\theta_2 = (\Pi, \Sigma)$ no lineales

El doble desafío

(ii) Con coeficiente aleatorios (BLP) las participaciones de mercado agregadas están dadas por:

$$\tilde{s}_j \equiv \tilde{s}_j^{RC}(\delta_1, \dots, \delta_J, \bar{\alpha}, \bar{\beta}, \Pi, \Sigma) \quad (7)$$

(ii) Los shares son *no lineales* en θ_2 (integral sobre i). (ii) p_{jt} es endógeno: $\text{Cov}(p_{jt}, \xi_{jt}) > 0$ por equilibrio oligopólico (las firmas fijan precio sabiendo ξ_{jt}).

El truco de Berry (1994): inversión de shares + GMM

1. **Inversión de shares (Berry, 1994).** Normalizando el bien externo ($\delta_{0t} = 0$), para cada θ_2 existe un único $\delta_{.t}(\theta_2)$ que iguala shares predichos y observados:

$$s_{jt} = \int \frac{\exp(\delta_{jt} + \mu_{ijt}(\theta_2))}{1 + \sum_k \exp(\delta_{kt} + \mu_{ikt}(\theta_2))} dF(D_i, v_i).$$

Logit puro: $\delta_{jt} = \ln s_{jt} - \ln s_{0t}$ (forma cerrada). Con coeficientes aleatorios la integral **se simula** y la inversión es un punto fijo (BLP, 1995).

2. **Linealidad recuperada.** Una vez obtenido $\delta_{jt}(\theta_2)$:

$$\xi_{jt}(\theta) = \delta_{jt}(\theta_2) - X_{jt}\beta - \alpha p_{jt}.$$

3. **GMM no lineal.** Con instrumentos Z y $\mathbb{E}[\xi_{jt} Z_{jt}] = 0$: $\hat{\theta}_2 = \arg \min_{\theta_2} \xi(\theta_2)' Z' W Z' \xi(\theta_2)$.

Berry (1994) aporta la inversión; el punto fijo anidado para coeficientes aleatorios es de BLP (1995).

Mapa de punto fijo (BLP, 1995)

$$\delta_{.t}^{(h+1)} = \delta_{.t}^{(h)} + \ln s_{.t}^{\text{obs}} - \ln s_{.t}(\delta_{.t}^{(h)}, \theta_2).$$

BLP prueban que es una **contracción en la norma del supremo** (constante de Lipschitz < 1): converge a la única $\delta(\theta_2)$ desde cualquier inicio.¹

Arquitectura computacional (NFP — *nested fixed point*)

- **Bucle externo (GMM)**: optimiza sobre $\theta_2 = (\Pi, \Sigma)$ (no lineales, pocos).
- **Bucle interno (contracción)**: resuelve $\delta(\theta_2)$ para cada candidato θ_2 .
- **Lineales** $\theta_1 = (\beta, \alpha)$: se *perfilan* (concentran) vía la CPO de IV/2SLS dado δ —
 $\hat{\theta}_1 = (X'ZWZ'X)^{-1}X'ZWZ'\delta$.

Alternativa moderna: Dubé, Fox & Su (2012) reemplazan el bucle interno por una restricción de optimización.

¹La constante de Lipschitz puede acercarse a 1 (p.ej. shares del bien externo cercanos a 0), degradando la convergencia del bucle interno.

El vector de momentos

$$\bar{g}_n(\theta) = \frac{1}{N} Z' \xi(\theta), \quad \mathbb{E}[\xi_{jt} Z_{jt}] = 0, \quad J = N \bar{g}_n(\hat{\theta})' \hat{S}^{-1} \bar{g}_n(\hat{\theta}) \xrightarrow{d} \chi^2_{q-p}.$$

Aquí $p = \dim(\theta_1) + \dim(\theta_2)$ cuenta *todos* los parámetros (lineales perfilados incluidos), no solo θ_2 .

Fuentes de instrumentos

- **BLP:** características de rivales (suma de X de otros productos de la misma/otra firma).
- **Costo:** *cost shifters* si están disponibles.
- **Nevo (2001):** precios en otras ciudades (Hausman) como *proxy* de costo común.
- **Differentiation IVs** (Gandhi & Houde, 2019).

Validez y advertencias

Las características de rivales son ortogonales a ξ_{jt} **solo bajo exogeneidad de características** ($\mathbb{E}[\xi_{jt} | X_{\cdot t}] = 0$) — supuesto fuerte, ya que las características se eligen. Los *BLP instruments* suelen ser **débiles** para Σ (de ahí los *differentiation IVs*). Los IV de Hausman fallan si hay shocks de demanda comunes entre ciudades (publicidad nacional, modas).

Nevo (2000, 2001): hacer BLP operativo

Dos contribuciones

- ***Practitioner's Guide* (JEMS 2000)**: el manual que volvió BLP estimable — perfilar los lineales, simulación de la integral, jacobiano analítico para la matriz de varianzas, manejo de la contracción. Ojo: el error de simulación sesga el estimador si el número de *draws* es fijo (Berry, Linton & Pakes, 2004).
- ***Ready-to-eat cereals* (Econometrica 2001)**: usa efectos fijos de marca para absorber ξ medio y mide poder de mercado/markups en una industria muy concentrada.

Preguntas para la exposición

- ¿Qué trucos computacionales propone para estimar BLP de forma eficiente y estable?
- ¿Qué instrumentos usa y por qué son válidos en este mercado?
- ¿Qué concluye sustantivamente sobre poder de mercado en cereales?

El paper lo exponen ustedes — los detalles los descubren leyendo (y corriendo) el código.

Por qué GMM es la herramienta natural para demanda

Lo que GMM aporta

- Maneja **no linealidad** en parámetros.
- No requiere distribución de ξ (a diferencia de MLE).
- Resuelve **endogeneidad de precios** con instrumentos.
- **Combina fuentes de datos** (micro D_i + agregados s_{jt}).
- Provee **test J** de validez de instrumentos.

Lo que cubrimos hoy y reaparece en BLP

- Vector $\bar{g}_n(\theta) = Z'\xi(\theta)/N$.
- Objetivo $\bar{g}_n'W\bar{g}_n$.
- Dos etapas con $\hat{W} = \hat{S}^{-1}$.
- Concentrar lineales vía IV/2SLS.
- Test J de sobreidentificación.

Eso es BLP. Lo único nuevo es la contracción anidada para δ .

“BLP es GMM (con simulación de la integral) más un bucle interno que invierte shares para recuperar δ .”

¿Qué es optimizar? ¿Por qué numéricamente?

Estimar es minimizar una función criterio

Casi todo estimador resuelve $\hat{\theta} = \arg \min_{\theta} Q(\theta)$ (MLE: $-\log L$; GMM: $\bar{g}_n' W \bar{g}_n$). La condición de primer orden (CPO) es $\nabla Q(\hat{\theta}) = 0$.

Con forma cerrada

Si la CPO es **lineal** en θ , se despeja a mano: OLS da $(X'X)^{-1}X'y$; IV, $(Z'X)^{-1}Z'y$. Una fórmula, sin iterar.

Sin forma cerrada

Si la CPO es **no lineal**, no hay despeje: hay que *buscar* la solución iterando $\Rightarrow$ aproximación numérica.

Dónde aparece en BLP

(i) $\delta(\theta_2)$ no tiene forma cerrada (punto fijo / contracción); (ii) θ_2 minimiza un GMM no lineal. Los lineales θ_1 se *perfilan* (forma cerrada), pero el **bucle sobre θ_2 y la inversión de *shares* se aproximan numéricamente**.

Cómo operan los métodos: iterar con información local

El esquema común a todos

$$\theta^{(k+1)} = \theta^{(k)} + t_k d_k \quad \text{hasta} \quad \|\nabla Q(\theta^{(k)})\| < \text{tol} \text{ ó } |\Delta Q| < \text{tol}.$$

Eligen una *dirección* d_k y un *paso* t_k usando solo información **local** (gradiente, curvatura) en $\theta^{(k)}$.

Mínimos locales vs. global

Garantizan a lo sumo un mínimo **local**. Si Q es *convexa* (OLS: suma de cuadrados; logit: $-\log L$), local = global. Si es *no convexa* (BLP), hay varios mínimos locales $\Rightarrow$ el resultado depende del punto inicial: **múltiples arranques**.

Multidimensionalidad y no convergencia

Con $\theta \in \mathbb{R}^p$, el Hessiano es $p \times p$ (invertir $\sim p^3$); proliferan puntos silla y direcciones casi planas. Objetivo ruidoso o mal condicionado $\Rightarrow$ el método se **estanca** o “converge” a un no-mínimo.

Por qué la implementación falla aunque la teoría sea correcta

La función objetivo $Q(\theta_2) = \bar{g}_n(\theta_2)' W \bar{g}_n(\theta_2)$ es **no convexa** en θ_2 , con *mínimos locales* y mesetas; el bucle interno (contracción) y la simulación de la integral inyectan *ruido* numérico en Q y en su gradiente.

Jerarquía de tolerancias

Tolerancia interna **varios órdenes más fina** que la externa (p.ej. 10^{-14} dentro, 10^{-6} fuera). Tolerancia interna floja $\Rightarrow$ gradiente externo basura (Dubé–Fox–Su, 2012).

Salida del optimizador $\neq$ estimador

El mismo código con distintos arranques/optimizadores puede dar resultados *muy* dispares, muchos ni siquiera son mínimos.

El error “matriz singular”: de dónde viene

El código de BLP invierte matrices en **cuatro** lugares; cada singularidad tiene una causa distinta.

Inversión en el código	Por qué se vuelve singular
Ponderación $W = (Z'Z)^{-1}$ ó $\hat{S}^{-1}$	Instrumentos colineales/redundantes : interacciones repetidas, <i>dummy trap</i> , Z con más columnas que productos.
Concentración lineal $\hat{\theta}_1 = (X'ZWZ'X)^{-1}X'ZWZ'\delta$	X colineal, o los instrumentos no abarcan X (falta relevancia/rango: $\text{rank}(Z'X) < \dim \theta_1$).
Varianzas $\hat{V} = (G'\hat{S}^{-1}G)^{-1}$	G casi deficiente : si σ_k es chico o los instrumentos son <i>débiles</i> para Σ , la columna asociada es casi nula (identificación débil/de borde).
Contracción / <i>shares</i> $\exp(\delta + \mu)$	No es inversión, pero el overflow de $\exp(\cdot)$ produce Inf/NaN y contamina toda la matriz.

Regla práctica: si aparece “singular”, preguntá cuál de las cuatro matrices, no toques el optimizador a ciegas.

Remediar

- **Instrumentos:** quitar colineales / reducir el set; *differentiation IVs* (Gandhi–Houde).
- **Escalar:** precios en miles, X estandarizadas; *log-sum-exp* restando el máximo evita el *overflow*.
- Múltiples arranques + gradientes analíticos (Nevo).
- **Reparametrizar Σ** (alternativa a las cotas del *solver*): factor de Cholesky o $\log \sigma$; si $\sigma_k \rightarrow 0$, ese parámetro **no está identificado**: sacarlo.
- **Resolver sistemas** (`solve(A,b)`, QR/Cholesky) en vez de invertir explícitamente; quitar mercados/productos con *shares* ≈ 0 .

Buenas prácticas consolidadas: Conlon & Gortmaker (2020, pyblp).

Dónde entra una covariable nueva

$$\delta_{jt} = \underbrace{X_{jt}^{(1)}\beta_1 + \alpha p_{jt}}_{\text{lineal: } \theta_1} + \xi_{jt} + \underbrace{\mu_{ijt}(\theta_2)}_{\text{no lineal}}.$$

con $X_{jt} = (X_{jt}^{(1)}, X_{jt}^{(2)})$. Una covariable w_{jt} va en $X^{(1)}$; con coeficiente aleatorio entra además en $X^{(2)}$ vía $\mu(\theta_2)$ y **ya no se concentra**. Si w es **endógena**, necesita instrumento aparte.

El truco de Nevo: perfilar + residualizar

(i) Concentrar: dado δ , θ_1 sale por la CPO de IV. **(ii) Absorber FE** (marca/mercado): por Frisch–Waugh *para IV*, residualizar respecto de los FE a δ , al precio p , a $X^{(1)}$ y **también a los instrumentos Z** .

Por qué importa numéricamente

El bucle no lineal sigue siendo solo θ_2 : **no** se estiman cientos de *dummies*. Matrices más chicas y mejor condicionadas $\Rightarrow$ menos singularidad.

*Alternativa: **micro-momentos** (Petrin, 2002) identifican Π con micro-datos que ligen demográficas y productos.*

Preguntas

Método de los momentos, GMM y teoría asintótica

Sargan, J. D. (1958). "The Estimation of Economic Relationships Using Instrumental Variables." *Econometrica* 26(3), 393–415.

Hansen, L. P. (1982). "Large Sample Properties of Generalized Method of Moments Estimators." *Econometrica* 50(4), 1029–1054.

White, H. (1980). "A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity." *Econometrica* 48(4), 817–838.

Newey, W. K. & West, K. D. (1987). "A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix." *Econometrica* 55(3), 703–708.

Chamberlain, G. (1987). "Asymptotic Efficiency in Estimation with Conditional Moment Restrictions." *Journal of Econometrics* 34(3), 305–334.

Manski, C. F. (1988). *Analog Estimation Methods in Econometrics*. Chapman & Hall.

Newey, W. K. & McFadden, D. (1994). "Large Sample Estimation and Hypothesis Testing." En *Handbook of Econometrics*, vol. 4, 2111–2245. Elsevier.

Hansen, L. P., Heaton, J. & Yaron, A. (1996). "Finite-Sample Properties of Some Alternative GMM Estimators." *Journal of Business & Economic Statistics* 14(3), 262–280.

Eficiencia, identificación débil e instrumentos

Cragg, J. G. (1983). "More Efficient Estimation in the Presence of Heteroscedasticity of Unknown Form." *Econometrica* 51(3), 751–763.

Bound, J., Jaeger, D. A. & Baker, R. M. (1995). "Problems with Instrumental Variables Estimation When the Correlation Between the Instruments and the Endogenous Explanatory Variable Is Weak." *Journal of the American Statistical Association* 90(430), 443–450.

Altonji, J. G. & Segal, L. M. (1996). "Small-Sample Bias in GMM Estimation of Covariance Structures." *Journal of Business & Economic Statistics* 14(3), 353–366.

Staiger, D. & Stock, J. H. (1997). "Instrumental Variables Regression with Weak Instruments." *Econometrica* 65(3), 557–586.

Stock, J. H. & Wright, J. H. (2000). "GMM with Weak Identification." *Econometrica* 68(5), 1055–1096.

Aplicación: retornos a la educación

Card, D. (1995). "Using Geographic Variation in College Proximity to Estimate the Return to Schooling." En *Aspects of Labour Market Behaviour: Essays in Honour of John Vanderkamp*, eds. L. N. Christofides et al., 201–222. University of Toronto Press.

Wooldridge, J. M. (2001). "Applications of Generalized Method of Moments Estimation." *Journal of Economic Perspectives* 15(4), 87–100.

Demanda en organización industrial (BLP / Nevo)

Berry, S. T. (1994). "Estimating Discrete-Choice Models of Product Differentiation." *RAND Journal of Economics* 25(2), 242–262.

Berry, S., Levinsohn, J. & Pakes, A. (1995). "Automobile Prices in Market Equilibrium." *Econometrica* 63(4), 841–890.

Nevo, A. (2000). "A Practitioner's Guide to Estimation of Random-Coefficients Logit Models of Demand." *Journal of Economics & Management Strategy* 9(4), 513–548.

Nevo, A. (2001). "Measuring Market Power in the Ready-to-Eat Cereal Industry." *Econometrica* 69(2), 307–342.

Petrin, A. (2002). "Quantifying the Benefits of New Products: The Case of the Minivan." *Journal of Political Economy* 110(4), 705–729.

Berry, S., Linton, O. B. & Pakes, A. (2004). "Limit Theorems for Estimating the Parameters of Differentiated Product Demand Systems." *Review of Economic Studies* 71(3), 613–654.

Optimización numérica y cómputo de BLP

Dubé, J.-P., Fox, J. T. & Su, C.-L. (2012). "Improving the Numerical Performance of Static and Dynamic Aggregate Discrete Choice Random Coefficients Demand Estimation." *Econometrica* 80(5), 2231–2267.

Knittel, C. R. & Metaxoglou, K. (2014). "Estimation of Random-Coefficient Demand Models: Two Empiricists' Perspective." *Review of Economics and Statistics* 96(1), 34–59.

Gandhi, A. & Houde, J.-F. (2019). "Measuring Substitution Patterns in Differentiated-Products Industries." NBER Working Paper 26375.

Conlon, C. & Gortmaker, J. (2020). "Best Practices for Differentiated Products Demand Estimation with PyBLP." *RAND Journal of Economics* 51(4), 1108–1161.